PHIÊN BẢN MVP 0.1.0 / NGÀY 22.10.2026

BÁO CÁO TÍNH NĂNG HIỆN TẠI

Website hỗ trợ tự học từ tài liệu cá nhân bằng RAG và mô hình ngôn ngữ nhỏ.

03	PDF / DOCX	35
Môn học được tổ chức	Định dạng đầu vào	Kiểm thử tự động đạt

1. Mục tiêu và đối tượng sử dụng

LearnStep hỗ trợ sinh viên học **Giải tích, Đại số tuyến tính và Vật lý đại cương**. Người dùng mang giáo trình của mình lên hệ thống, đặt câu hỏi và đọc giải thích có nguồn đối chiếu. Quy mô thiết kế ban đầu là demo đồ án cho khoảng 5-10 người thử nghiệm.

2. Nhóm tính năng đã triển khai trong mã nguồn

Nhóm	Khả năng hiện có
Tài khoản	Đăng ký, đăng nhập, xác nhận email, đặt lại mật khẩu và đăng xuất.
Thư viện tài liệu	Upload PDF/DOCX riêng tư, gán môn học, chọn tài liệu, theo dõi xử lý, thử lại và xóa.
Trợ giảng AI	Truy xuất RAG, hỏi đáp tiếng Việt, ngữ cảnh hội thoại gần nhất, LaTeX và trích dẫn.
Giao diện	Phong cách Lingo; font Nunito; nút nổi, thẻ bo tròn; bố cục desktop và tab mobile.
Vận hành	Worker cục bộ, hàng đợi bền vững, heartbeat, giới hạn sử dụng và bộ công cụ đánh giá.

Phạm vi xác nhận

Báo cáo mô tả **mã nguồn hiện có** và kết quả kiểm tra tại máy. Chưa có cấu hình kết nối cloud trong workspace và chưa xác nhận luồng tích hợp thật với Supabase, Qdrant Cloud, Ollama hoặc URL Vercel. Các tính năng AI cần đủ các dịch vụ này để sử dụng thực tế.

01 / TÀI KHOẢN VÀ TÀI LIỆU

Mang tài liệu vào góc học tập

Luồng chính: đăng nhập, tải tài liệu, đợi xử lý thành công rồi chọn tài liệu để hỏi đáp.

Tài khoản cá nhân

Đăng ký và xác nhận email. Giao diện kết nối Supabase Auth; hỗ trợ callback PKCE và xác nhận bằng token hash.

Khôi phục truy cập. Gửi email đặt lại mật khẩu, nhập mật khẩu mới và đăng xuất. Giao diện yêu cầu mật khẩu ít nhất 8 ký tự; cấu hình Auth phải được áp dụng tương ứng.

Không gian riêng. Tài liệu, hội thoại, câu trả lời và tác vụ được gắn với tài khoản. Người chưa đăng nhập được chuyển tới trang xác thực.

Quản lý tài liệu

Tính năng	Hành vi và giới hạn
Tải file	PDF hoặc DOCX, tối đa **20 MB/file**; tối đa **20 tài liệu/tài khoản**. Trình duyệt tải trực tiếp vào bucket private bằng signed upload URL.
Kiểm tra đầu vào	API kiểm tra metadata dung lượng/MIME; worker kiểm tra nội dung thực tế. PDF tối đa **200 trang**; văn bản trích xuất tối đa **1 triệu ký tự**. DOCX giải nén tối đa **80 MB**.
Tổ chức và lựa chọn	Gán một trong ba môn học. Mỗi câu hỏi chọn **1-5 tài liệu** đã sẵn sàng; giao diện hiển thị tên, môn, dung lượng và trạng thái.
Theo dõi / thử lại	Trạng thái tải lên, chờ, xử lý, sẵn sàng, thất bại và đang xóa. Có thông báo lỗi, xác nhận lại file tải dở và thử lại ingestion bị lỗi.
Xóa và dọn dữ liệu	Loại tài liệu khỏi truy xuất ngay khi bắt đầu xóa. Worker dọn file, vector và chunks; nguồn trong hội thoại cũ báo không còn khả dụng.

Dọn dẹp có thể tiếp tục sau gián đoạn

Worker tiếp tục tác vụ còn trong queue khi khởi động lại. Upload bỏ dở được đưa vào cleanup sau 24 giờ. Có lượt quét lại tombstone để dọn file nếu signed upload token cũ còn hiệu lực.

02 / HỎI ĐÁP VÀ TRÍCH DẪN

Học bằng câu hỏi có ngữ cảnh

Trang học tập gồm thư viện, hội thoại và nguồn tham khảo. Trên màn hình nhỏ, các khu vực chuyển thành tab; hỗ trợ chuyển tab bằng phím mũi tên, Home và End.

Pipeline hỏi đáp đã triển khai

Bước	Xử lý
1. Trích xuất	PyMuPDF đọc PDF theo trang; python-docx đọc đoạn, tiêu đề và bảng trong DOCX.
2. Tạo chỉ mục	Chia khoảng **500 token/đoạn**, chồng lấp **80 token**, giữ vị trí nguồn; BGE-M3 tạo dense vector 1024 chiều, ghi vào Qdrant.
3. Tìm nội dung	Truy vấn lọc theo người dùng, tài liệu và index version. Lấy tối đa **8 ứng viên**, loại trùng và chọn tối đa **5 đoạn** trong ngân sách context.
4. Tạo câu trả lời	Qwen3 4B qua Ollama được hướng dẫn trả lời tiếng Việt, từng bước và có nhãn S1-S5. Dùng tối đa 6 message lịch sử, giới hạn 450 token.
5. Hiển thị	Worker lưu dần nội dung; UI cập nhật khi đọc trạng thái khoảng mỗi 2 giây trong lúc có tác vụ. Đây là polling, không phải streaming trực tiếp từ Vercel.

Nguồn tham khảo và công thức

Đối chiếu nguồn. Mỗi nguồn có tên tài liệu và trang PDF hoặc mục/đoạn DOCX. Bấm trích dẫn để đọc đoạn gốc; PDF có URL đọc riêng tư, hiệu lực 120 giây và mở đúng trang.

Công thức LaTeX. Markdown và KaTeX hiển thị công thức inline hoặc khối. HTML thô không được thực thi; ảnh từ câu trả lời không tự tải về.

Lịch sử phiên học. Lưu câu hỏi/câu trả lời theo tài khoản, tạo phiên mới và mở lại hội thoại. API danh sách hiển thị tối đa 100 hội thoại gần nhất.

Khi chưa đủ bằng chứng

Hệ thống có nhánh trả lời chưa tìm thấy thông tin phù hợp. Nhãn trích dẫn không thuộc context bị từ chối. Nhãn hợp lệ **không tự chứng minh lời giải đúng**; chất lượng suy luận và mức độ nguồn hỗ trợ vẫn phải được chấm thủ công.

03 / KIẾN TRÚC VÀ VẬN HÀNH

Web trên cloud, AI tại máy cá nhân

Thành phần	Vai trò hiện có
Next.js / TypeScript	Giao diện và API; đã có cấu hình Vercel, region sin1. File đi trực tiếp tới Storage; API không chờ model sinh xong.
Supabase	Auth, PostgreSQL, bucket private và Queues. RPC tạo dữ liệu nghiệp vụ và enqueue trong cùng transaction.
Qdrant Cloud	Collection embedding phiên bản hóa, dense vector cosine, payload index và bộ lọc quyền sở hữu.
Python / Ollama	Worker chủ động lấy việc, gọi parser, embedding, retrieval và SLM. Ollama chỉ ở localhost; không cần public endpoint máy cá nhân.

Cơ chế bảo vệ dữ liệu trong mã nguồn

Phân quyền nhiều lớp. Cookie Supabase SSR và RLS; RPC lấy chủ sở hữu từ auth.uid(). Client không được ghi trực tiếp messages, jobs, chunks hoặc nhận việc từ queue.

Truy xuất có ràng buộc. Qdrant lọc user/document/version; worker đọc lại chunk trong PostgreSQL trước khi đưa vào context. Secret chỉ được cấu hình phía server/worker.

Xóa và job cũ. Kiểm tra lại trạng thái/phiên bản tài liệu khi publish. UUID vector ổn định, idempotency key và lease token giúp xử lý việc nhận lại job.

Giới hạn và điều phối

Cấu hình	Giá trị mặc định
Tài khoản / câu hỏi	Một câu hỏi đang chờ/chạy mỗi tài khoản; 30 câu hỏi/giờ; nội dung tối đa 2.000 ký tự.
Song song / bộ nhớ	Một consumer AI cho mỗi database bằng session advisory lock; giải phóng model embedding trước SLM và ngược lại.
Heartbeat / offline	Heartbeat 15 giây; không có cập nhật hơn 60 giây thì báo offline và không nhận thêm tác vụ AI mới.
Retry / lease	Tối đa 3 lượt xử lý; lỗi tạm chờ 10 giây; visibility timeout 120 giây và được gia hạn.
SLM	qwen3:4b; thinking tắt; context 4.096 token; đầu ra tối đa 768 token. Cần benchmark trên máy thật.

04 / KIỂM CHỨNG VÀ GIỚI HẠN

Mức độ sẵn sàng hiện tại

Hạng mục	Kết quả tại máy / phạm vi
Web / API	**9 kiểm thử đạt**: validation, Markdown/LaTeX, chặn request không hợp lệ và ranh giới xác thực.
Database	**10 kiểm thử đạt** trên PostgreSQL nhúng PGlite: RLS, grants, quota, idempotency, rollback enqueue và tombstone nguồn. Auth/Storage/PGMQ có thành phần thay thế tối thiểu.
Worker	**16 kiểm thử đạt**: parser, chunking, tenant/version filters, trích dẫn, stream gián đoạn, fencing và bộ đánh giá. Vector chạy in-memory; inference có HTTP mock.
TypeScript / build	Typecheck và production build đã thành công. Có GitHub Actions cho web/database và worker.
Cloud / model thật	**Chưa xác minh tích hợp đầu-cuối.** Chưa có cấu hình cloud tại workspace; chưa công bố URL deploy hoặc số đo chất lượng/tốc độ model thật.

Công cụ đánh giá đã có

Bộ mẫu tự biên soạn gồm **6 tài liệu và 60 câu hỏi**: 45 câu có bằng chứng, 15 câu thiếu bằng chứng; chia 20 calibration và 40 test. Có lệnh tạo corpus, đánh giá RAG, xuất kết quả chấm và benchmark Ollama. Đây là fixture nhỏ, cần bổ sung giáo trình thật trước khi kết luận chất lượng học thuật.

Các giới hạn cần biết

Chưa có OCR, đọc PDF scan, nhận dạng công thức/sơ đồ trong ảnh, tạo đề ôn tập, lộ trình cá nhân hoặc LoRA/QLoRA. DOCX không có số trang cố định. Chưa có query rewriting, reranker hay hybrid search. Máy chạy AI phải bật và có Internet; heartbeat chỉ phản ánh worker, không bảo đảm mọi dịch vụ upstream luôn sẵn sàng.

Các bước tiếp theo để nghiệm thu thực tế

1. Cấu hình Supabase, Qdrant và Ollama, áp dụng migration.
2. Chạy worker và deploy Next.js lên Vercel.
3. Smoke test bằng hai tài khoản, gồm upload, hỏi đáp, trích dẫn, xóa và khôi phục lỗi.
4. Chạy model thật, chấm bộ test và đo thời gian/VRAM trước khi công bố đạt mục tiêu.

Cơ sở lập báo cáo

Đối chiếu mã nguồn và tài liệu trong repository ngày 22/10/2026: apps/web/src/app; apps/web/src/components; services/worker/src/study_worker; supabase/migrations/202610220001_initial.sql; docs/architecture.md; docs/evaluation.md; các bộ kiểm thử web/database/worker. Tên thương hiệu đã thống nhất là LearnStep; namespace kỹ thuật và dữ liệu lưu trữ hiện có được giữ để tránh phá tương thích.